WMT2020（英中）

News Translation Task

newstest2020: English to/from Chinese

ニュースの原入力と参照訳で、英中の翻訳を評価する

sasakiy84

WMT20 ニュース翻訳タスクの公式サイト

EMNLP 2020
FIFTH CONFERENCE ON
MACHINE TRANSLATION (WMT20)

November 19-20, 2020
Online

Shared Task: Machine Translation of News

[HOME] [SCHEDULE] [PAPERS] [VIRTUAL CONFERENCE] [RESULTS]
TRANSLATION TASKS: [NEWS] [LIFELONG LEARNING] [ROBUSTNESS] [SIMILAR LANGUAGES] [UNSUP AND VERY LOW RES] [BIOMEDICAL] [CHAT]
OTHER TASKS: [AUTOMATIC POST-EDITING] [METRICS] [QUALITY ESTIMATION] [PARALLEL CORPUS FILTERING]

The recurring translation task of the WMT workshops focuses on news text. For this year the language pairs are:

- Chinese-English
- Czech-English (this year **both directions again**)
- French-German
- German-English
- Inuktitut-English
- Khmer-English
- Japanese-English
- Pashto-English
- Polish-English
- Russian-English
- Tamil-English

We provide parallel corpora for all languages as training data, and additional resources for download.

GOALS

[1] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

1. 原入力から、別の言語へ訳す
2. ニュース文書と参照訳の構成
3. BLEU と、 2020 年の人手評価
4. CLEVA での採用と利用条件

原文の内容を、もう一つの言語へ

英語から中国語、中国語から英語へ

- WMT2020 のニュース翻訳では、入力の内容を別の言語で表す。本資料は公開テスト newstest2020 の英→中と中→英を扱う。
- 入力と対応する参照訳が公開されている。参照訳は比較のための訳文であり、同じ内容を表す唯一の正解ではない。
- 二つの翻訳方向は、それぞれ原言語の異なるニュース文書から作られた。同じ対を逆向きにして、独立した例を増やしていない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例１：壁をめぐる非難と、拒否権の意向

英→中 / foxnews.100085 / seg 1 / 全体 index 910

入力（英語）
House rebukes Trump on border wall, but he plans veto

参照訳（中国語）
众议院在边境墙问题上指责特朗普，但他计划使用一票否决权

入力の日本語訳
国境の壁をめぐり下院がトランプ氏を非難するが、同氏は拒否権を行使する意向だ。

参照訳の日本語訳
下院は国境の壁の問題でトランプ氏を非難するが、同氏は拒否権を使う予定だ。

[1] WMT20. newstest2020 / enzh / foxnews.100085 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

下院の非難と、拒否権行使の意向

- House は下院、 rebukes は非難。対立する but 節と、 plans が示す意向を保つ。
- 主節の非難と、 but 節の反対の動きを一つの見出しに保つ。plans は実行済みの拒否ではなく、行使する意向を表す。
- この原入力と参照訳は、 CLEVA の紙面例と一致する。ここでは、WMT2020 の公開テストにある一つの区間として示した。

[1] WMT20. newstest2020 / enzh / foxnews.100085 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例２：女性への抑圧に抗した人物を伝える

英→中 / en.ndtv.com.13041 / seg 8 / 全体 index 1411

入力（英語）
This will help the present generation to know about the man, who had waged a war against women oppression and propagated widow remarriage, he said.

参照訳（中国語）
他说，这将有助于当代人了解这位名人，他发动了一场反对妇女压迫的战争，并鼓励寡妇再婚。

入力の日本語訳
女性への抑圧と闘い、寡婦の再婚を推進したこの人物について、現代の人々が知る助けになる、と彼は述べた。

参照訳の日本語訳
これは、女性への抑圧に反対する闘いを起こし、寡婦の再婚を奨励したこの著名人を、現代の人々が知る助けになる、と彼は述べた。

[1] WMT20. newstest2020 / enzh / en.ndtv.com.13041 / seg 8. https://data.statmt.org/wmt20/translation-task/test.tgz

実例３：固有名詞と、列挙された役職

中→英 / chinanews.com.102568 / seg 3 / 全体 index 18

入力（中国語）
中国驻柬大使馆外交官仲跻法、柬华理事总会代表、柬埔寨江西商会会长魏思钰等为获奖嘉宾颁奖。

参照訳（英語）
Zhong Jifa, diplomat of the Chinese Embassy in Cambodia, and Wei Siyu, representative of the Cambodian Chinese Council and President of Jiangxi Chamber of Commerce in Cambodia, presented the awards to the winners.

入力の日本語訳
中国駐カンボジア大使館の外交官・仲跻法、カンボジア華人理事総会の代表、カンボジア江西商会会長・魏思钰らが、受賞者に賞を贈った。

参照訳の日本語訳
カンボジアの中国大使館の外交官・仲跻法と、カンボジア華人理事総会代表兼カンボジア江西商会会長・魏思钰が、受賞者に賞を贈った。

[1] WMT20. newstest2020 / zhen / chinanews.com.102568 / seg 3. https://data.statmt.org/wmt20/translation-task/test.tgz

単語の対応と、文の役割を保つ

- 長い関係節が the man を説明する。女性への抑圧に反対したことと、再婚の推進を両方保つ。
- 人名や機関名のある文では、誰がどの役職で、何をしたのかを読み分ける。長い列挙でも、受賞者へ賞を贈ったという動作を保つ。
- 表示したのは各 SGM の 1 区間の全文と、その区間に対応する参照訳の全文。記事全体を入力にした実行結果ではない。

[1] WMT20. newstest2020 / enzh / en.ndtv.com.13041 / seg 8. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] WMT20. newstest2020 / zhen / chinanews.com.102568 / seg 3. https://data.statmt.org/wmt20/translation-task/test.tgz

ニュース記事を、評価用の翻訳対へ

WMT2020 全体と、英中の公開テスト

- WMT20 のニュース翻訳は 11 言語対、 22 方向を含む国際共有タスク。本資料はそのうちの英語・中国語の二方向に絞る。
- ニュースサイトの原文を収集し、評価用の翻訳を作成した。入力が翻訳文になることを避けるため、各方向の原言語の文書を使う。
- 学習用の対訳・単言語コーパス、開発データ、公開テストは別の資源。 WMT14 など、別年のテストも同じ集合とは扱わない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

英→中 1,418 区間、中→英 2,000 区間

方向	区間数	文書数	原文の言語
英→中	1,418	130	英語のみ
中→英	2,000	155	中国語のみ

SGM の docid と seg id を再集計。区間数と記事数は異なる。各方向で原入力の重複・空欄は 0 。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

英→中では、一つの区間が複数文を含む

- 英→中では、翻訳者へ文単位ではなく段落の区切りを保った文章を渡した。翻訳時に文を結合・分割する自由度を持たせている。
- 公式サイトも、一つの区間が通常より長く、複数の文を含む場合があると説明する。 seg を一律に一文と数えない。
- 公開 SGM は、文書の docid と区間の id を持つ。同じ seg id が別の記事にも現れるため、二つを組にして対応付ける。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

同じ入力に、異なる参照ファイルがある

比較	英→中	中→英
通常配布と B 配布の入力	全 1,418 区間で一致	全 2,000 区間で一致
参照文が異なる区間	1,416 / 1,418	1,997 / 2,000
通常配布の名前	newstest2020	newstest2020
別参照を持つ名前	newstestB2020	newstestB2020

入力が同じなので、 B 配布を追加の独立した入力例として数えない。本資料の 13 例は通常配布の参照を使用。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

参照の表現が、語句の一致を変える

House rebukes Trump on border wall, but he plans veto

公開参照（中国語）	意味の日本語訳
众议院在边境墙问题上指责特朗普，但他计划使用一票否决权	下院は国境の壁の問題でトランプ氏を非難するが、同氏は拒否権を使う予定だ。
众议院就边境城一事谴责特朗普，而特朗普打算否决	下院は国境の都市の件でトランプ氏を非難し、トランプ氏は否決するつもりだ。

上： newstest2020 、下： newstestB2020 。「边境城」は B 配布の原形を保持。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

学習資源の制約も、性能の条件になる

- 共有タスクでは、提供された学習資源に従う constrained 条件と、それを超える資源を使う条件を区別する。テストの対だけで学習条件は決まらない。
- ニュース翻訳のシステムは、対訳データ、単言語データ、逆翻訳、モデルの組合せなどを利用した。個別のシステム構成は参加論文で説明される。
- ここで示す 13 例は公開テストの原入力と参照訳。実際のモデル出力や、未取得の CLEVA の学習・提示データではない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

語句の一致と、人の判断を分ける

BLEU は、翻訳内容の正答率ではない

- BLEU は、出力と参照の n-gram の重なりを数える。通常は 1 〜 4-gram の修正適合率を幾何平均し、短い出力へ長さのペナルティを掛ける。
- 修正適合率は、出力中の全 n-gram に対する、参照と一致する n-gram の割合。一致数は参照の出現回数を上限とし、繰り返しによる水増しを抑える。
- n-gram は n 個のトークンの連続列。複数区間の一致数と長さをまとめてコーパスの BLEU を求め、区間ごとの BLEU の単純平均とは区別する。

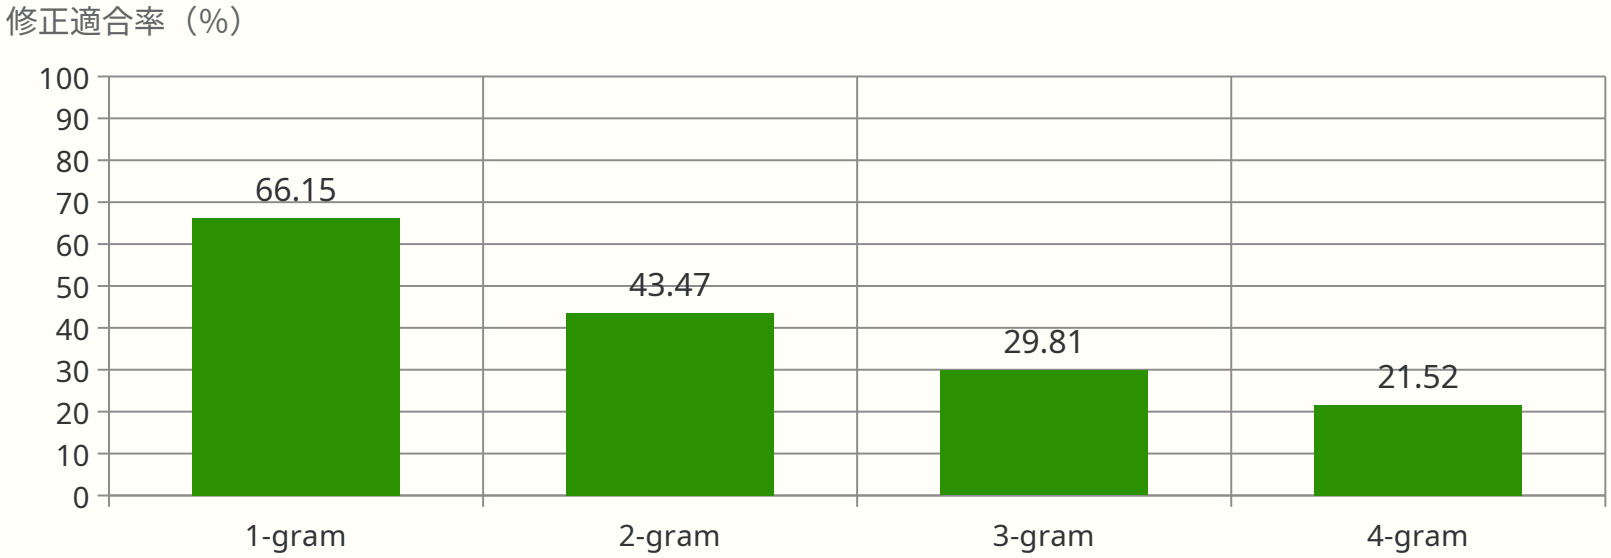
[1] Papineni, Roukos, Ward & Zhu (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. ACL. https://aclanthology.org/P02-1040/

言語の区切り方と、版を明示する

- 中国語の分割方法は得点に影響する。この計算の zh 分割は漢字などを 1 字ずつに分け、非漢字部分にも区切り処理を行う。
- SacreBLEU は、参照や分割方法などの条件を再現しやすくする評価ツール。版、大小文字、参照数、 tokenizer をそろえて値を読む。
- 次の計算例は SacreBLEU 2.5.1 、参照 1 本、大小文字を保持、 zh 分割。 WMT2020 や、未取得の CLEVA 実行の採点条件を再現した値ではない。

[1] Post (2018). A Call for Clarity in Reporting BLEU Scores. WMT, pp.186–191. https://aclanthology.org/W18-6319/
[2] Post et al. SacreBLEU 2.5.1. Local reference-to-reference calculation, fixed tokenization. https://github.com/mjpost/sacrebleu/tree/v2.5.1

公開参照同士でも、 BLEU は 36.85 になる



通常配布参照を出力側、 B 配布参照を参照側に置いた計算例。英→中の全 1,418 区間。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. Local reference-to-reference calculation, fixed tokenization. https://github.com/mjpost/sacrebleu/tree/v2.5.1

2020 年の人手評価は、別の尺度を使う

評価対象	平均評点	標準化平均（ z ）
HUMAN-B	80.6	0.568
HUMAN-A	82.5	0.529
OPPO	80.0	0.447
Tencent-Translation	79.0	0.420
Huawei-TSC	77.3	0.415

英→中。 HUMAN-A/B は評価した人手訳、 3 システムは資源制約内。 DA 評点（ 0 〜 100 ）は正答率ではない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

人手評価は、文書の文脈を見て採点する

- 英語からの翻訳では、原文と翻訳を示し、文書全体を見ながら個々の区間や文書を評価する方式を使った。意味がどれほど適切に伝わるかを人が判断する。
- 採点者ごとの評点の傾向を平均と標準偏差で標準化し、平均 z 得点を求める。生の平均評点と、標準化後の並び順が同じになるとは限らない。
- 会議の公式順位は統計的な同順位群も持つ。上の小数点の差を、すべて有意な性能差と扱わない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

公開例の出所と、実行の範囲を追う

CLEVA の公開例は、 2020 年の配布へ一致

- CLEVA は、過去の WMT 大会から英中翻訳データを集め、SacreBLEU で評価すると説明する。紙面自体は、採用データの年を一つに限定していない。
- 紙面の下院見出しと、 HELM の二つの翻訳説明例は、 WMT2020 通常配布の原入力・参照訳へ完全一致する。
- この一致が示すのは、公開例の出所。 CLEVA の全翻訳集合が WMT2020 だけであることや、 B 配布を使わないことまで証明するものではない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM. CLEVATranslationScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

HELM の設定と、公開された実行を分ける

対象	確認できる内容
CLEVA translation v1	en2zh / zh2en の二つの下位課題
prompt_id	各方向 0 〜 2 、各 3 設定
Classic 公開索引	8,526 spec 中、 CLEVA 名の実行 0 件
未取得の実体	選定集合全体、 templates 、 infer_params

設定の数はモデル数や生成候補数ではない。実際の得点・提示例数・温度は補っていない。

[1] Stanford CRFM. CLEVA v1 run settings, translation en2zh / zh2en. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf
[2] Stanford CRFM. HELM Classic v0.4.0 public run index. https://crfm.stanford.edu/helm/classic/v0.4.0/

公開実装から分かることにも限界がある

- HELM v0.4.0 は、変換済みデータとテンプレートから翻訳入力と参照を作る。生成条件は infer_params.json から読む。
- 採点設定は翻訳用の CLEVAMachineTranslationMetric クラスを指定する。しかし、その配置先の machine_translation_metrics.py は、同版の公開 metrics 一覧にない。
- そのため、固定公開版だけから CLEVA の分割方法や集約を再現できたとは述べない。前の参照同士の計算は、条件を明示した別の説明用計算である。

[1] Stanford CRFM. get_cleva_spec / get_cleva_machine_translation_metric_specs. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/run_specs.py

[2] Stanford CRFM. Public metrics directory at HELM v0.4.0. https://github.com/stanford-crfm/helm/tree/v0.4.0/src/helm/benchmark/metrics

研究利用と、ニュース本文の権利を分ける

- 公式タスクページは、 WMT20 のデータを研究目的で自由に使えるとし、概要論文と各集合の追加引用条件を守るよう求める。
- それ以外の用途は元データの権利者へ相談するという条件。公開ダウンロードが、ニュース本文の権利の放棄を意味するわけではない。
- 本資料は識別可能な短い 13 区間を、出所と参照訳とともに示す。ニュースの原記事全体や、データ全量の追加配布は作っていない。

[1] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

入力・参照・方向・尺度をそろえて読む

- WMT2020 英中は、原言語の異なるニュース文書を二方向へ翻訳する公開テスト。文章区間と文書の単位を分け、対応する参照を使う。
- BLEU は参照の表現や分割条件で変わり、人の意味判断と同じ尺度ではない。 2020 年の会議の評価と、説明用の再計算も区別する。
- CLEVA の公開例は出所を追跡できる一方、選定集合全体と推論条件は未確定。元 WMT データの全件数を、そのまま CLEVA の実行数へ置き換えない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加の公開翻訳例
2. 原位置・計算・公開実装
3. 研究と参考文献

追加の公開翻訳例

実例 4 ： 5 日間で 500 通の手紙

英→中 / cnn.385674 / seg 1 / 全体 index 24

入力（英語）
A woman in Maine got 500 letters from United Healthcare within five days

参照訳（中国語）
一位缅因州女性五天内收到 500 封来自联合健康保险的信件

入力の日本語訳
メーン州の女性が、ユナイテッドヘルスケアから 5 日間で 500 通の手紙を受け取った。

参照訳の日本語訳
メーン州のある女性が、 5 日間でユナイテッドヘルスケアから 500 通の手紙を受け取った。

[1] WMT20. newstest2020 / enzh / cnn.385674 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 5 ： SNS の「いいね」を非表示にする

英→中 / rte.en.ie.5333 / seg 1 / 全体 index 101

入力（英語）
Facebook hides 'likes' in new Australia trial

参照訳（中国語）
脸书在澳大利亚新测试中隐藏点“赞”数

入力の日本語訳
Facebook が、オーストラリアでの新たな試験で「いいね」を非表示にする。

参照訳の日本語訳
Facebook が、オーストラリアでの新たな試験で「いいね」の数を非表示にする。

[1] WMT20. newstest2020 / enzh / rte.en.ie.5333 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 6 ：ハリケーンの強さと場所

英→中 / upi.205660 / seg 1 / 全体 index 114

入力（英語）
Lorenzo strengthens into Category 4 hurricane east of Caribbean

参照訳（中国語）
洛伦佐在加勒比海东部增强为 4 级飓风

入力の日本語訳
ロレンゾが、カリブ海の東でカテゴリー 4 のハリケーンに発達する。

参照訳の日本語訳
ロレンゾが、カリブ海の東部でカテゴリー 4 のハリケーンに勢力を強める。

[1] WMT20. newstest2020 / enzh / upi.205660 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 7 ： AI を共通善のために使う

英→中 / seattle_times.7657 / seg 1 / 全体 index 164

入力（英語）
Pope warns tech execs to use AI for the common good

参照訳（中国語）
教皇方济各就技术高管使用人工智能实现公共利益发出警告

入力の日本語訳
教皇が、共通善のために AI を使うようテクノロジー企業の幹部に注意を促す。

参照訳の日本語訳
教皇フランシスコが、公共の利益のために AI を使うことについて、テクノロジー企業の幹部に注意を促す。

[1] WMT20. newstest2020 / enzh / seattle_times.7657 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 8 ：礼節ある政治家を表彰する制度

英→中 / standard.co.uk.14676 / seg 2 / 全体 index 230

入力（英語）
A new awards scheme has been set up to recognise politicians who show courtesy in their work.

参照訳（中国語）
设立新的奖项计划是为了表彰那些礼貌得体的政治人士

入力の日本語訳
仕事で礼節を示す政治家をたたえるため、新たな表彰制度が設けられた。

参照訳の日本語訳
新たな表彰計画を設けるのは、礼儀正しく品位のある政治家をたたえるためだ。

[1] WMT20. newstest2020 / enzh / standard.co.uk.14676 / seg 2. https://data.statmt.org/wmt20/translation-task/test.tgz

実例９：協定が許す遠心分離機を限定する

中→英 / international_times-zh.151 / seg 4 / 全体 index 30

入力（中国語）
协议规定，伊朗只能用第一代 IR-1 型离心机来提炼铀。

参照訳（英語）
The agreement stipulates that Iran can only use first-generation IR-1 centrifuges to refine uranium.

入力の日本語訳
協定では、イランがウラン精製に使えるのは第 1 世代の IR-1 型遠心分離機だけと定めている。

参照訳の日本語訳
協定は、イランがウラン精製に使えるのは第 1 世代の IR-1 型遠心分離機だけと規定する。

[1] WMT20. newstest2020 / zhen / international_times-zh.151 / seg 4. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 10 ：クルーズ船に初めて乗る参加者

中→英 / hunan_ribao-zh.186 / seg 2 / 全体 index 96

入力（中国語）
参加此次活动的 100 余名残障人士大多是第一次登上邮轮。

参照訳（英語）
Most of the more than 100 disabled people who participated in the event had never boarded a cruise ship before.

入力の日本語訳
今回の催しに参加した 100 人余りの障害者の多くは、クルーズ船に乗るのが初めてだった。

参照訳の日本語訳
この催しに参加した 100 人余りの障害者の多くは、それまでクルーズ船に乗ったことがなかった。

[1] WMT20. newstest2020 / zhen / hunan_ribao-zh.186 / seg 2. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 11 ： 8 月の世界販売台数を伝える

中→英 / nikkei-.108 / seg 1 / 全体 index 146

入力（中国語）
马自达 9 月 27 日发布的数据显示，8 月全球销量为 11 万 7015 辆。

参照訳（英語）
According to data released by Mazda on September 27, global sales in August were 117015 units.

入力の日本語訳
マツダが 9 月 27 日に発表したデータによると、 8 月の世界販売は 11 万 7015 台だった。

参照訳の日本語訳
マツダが 9 月 27 日に発表したデータによると、 8 月の世界販売は 117,015 台だった。

[1] WMT20. newstest2020 / zhen / nikkei-.108 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 12 ：壁画が描く人物の生涯

中→英 / xinhua-zh-01.6415 / seg 2 / 全体 index 228

入力（中国語）
《天后圣迹图》是一幅全面反映妈祖生平的大型传统壁画。

参照訳（英語）
The Drawing of Miracles of Mazu is a large traditional mural that fully reflects Mazu's life.

入力の日本語訳
『天后聖蹟図』は、媽祖の生涯を全面的に描いた大きな伝統的壁画である。

参照訳の日本語訳
『媽祖の奇跡の図』は、媽祖の生涯を全面的に描いた大きな伝統的壁画である。

[1] WMT20. newstest2020 / zhen / xinhua-zh-01.6415 / seg 2. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 13 ：空港の供用開始の式典

中→英 / chinanews.com.102714 / seg 1 / 全体 index 238

入力（中国語）
9 月 25 日，北京大兴国际机场投运仪式隆重举行。

参照訳（英語）
On September 25th, a grand opening ceremony was held for the Beijing Daxing International Airport.

入力の日本語訳
9 月 25 日、北京大興国際空港の供用開始の式典が盛大に催された。

参照訳の日本語訳
9 月 25 日、北京大興国際空港で盛大な開業式典が催された。

[1] WMT20. newstest2020 / zhen / chinanews.com.102714 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

各実例で、何を保って訳すか

実例	対応の手掛かり
1	House は下院、 rebukes は非難。対立する but 節と、 plans が示す意向を保つ。
2	長い関係節が the man を説明する。女性への抑圧に反対したことと、再婚の推進を両方保つ。
3	人名、機関名、役職、授賞という動作の対応を読む。公開参照訳の表現を唯一の正解とは扱わない。
4	数量 500 と期間 5 日を取り違えない。地名と企業名も翻訳に含む。

説明は本資料による。原入力と参照訳を同じ意味の日本語へ無理にそろえていない。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

各実例で、何を保って訳すか

実例	対応の手掛かり
5	引用符付きの likes は SNS の反応。参照訳は点赞数と、数であることを明示する。
6	固有名詞とカテゴリー 4 、 east of が示す位置を保つ。
7	参照訳は教皇の名前を補う。原入力の明示語と、参照訳の具体化を分けて読む。
8	has been set up は設立済みであることを示す。 to recognise 以下は表彰する目的。
9	只能／ only が機器を限定する。 IR-1 という型式を、そのまま保つ。

説明は本資料による。原入力と参照訳を同じ意味の日本語へ無理にそろえていない。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

各実例で、何を保って訳すか

実例	対応の手掛かり
10	100 人余りという全体と、その多くという範囲を分ける。初めてを、過去の経験の否定として表す。
11	中国語の万の単位を、英語では 117015 へ直す。発表日と販売対象月を混同しない。
12	作品名は英語参照訳で意味を説明する形になる。原題と訳題を別々の作品としない。
13	日付と空港名を保つ。投运は施設の稼働開始。参照訳では grand opening とする。

説明は本資料による。原入力と参照訳を同じ意味の日本語へ無理にそろえていない。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

原位置・計算・公開実装

原文書と区間を、組で固定する

例	方向 / 全体 index	docid	seg id
1	enzh / 910	foxnews.100085	1
2	enzh / 1411	en.ndtv.com.13041	8
3	zhen / 18	chinanews.com.102568	3
4	enzh / 24	cnn.385674	1
5	enzh / 101	rte.en.ie.5333	1
6	enzh / 114	upi.205660	1
7	enzh / 164	seattle_times.7657	1

全体 index は 0 起算、 seg id は配布原形。 SGM 行番号、行 SHA256 、 byte offset 、対応参照を原記録へ保存。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

原文書と区間を、組で固定する

例	方向 / 全体 index	docid	seg id
8	enzh / 230	standard.co.uk.14676	2
9	zhen / 30	international_times-zh.151	4
10	zhen / 96	hunan_ribao-zh.186	2
11	zhen / 146	nikkei-.108	1
12	zhen / 228	xinhua-zh-01.6415	2
13	zhen / 238	chinanews.com.102714	1

全体 index は 0 起算、 seg id は配布原形。 SGM 行番号、行 SHA256 、 byte offset 、対応参照を原記録へ保存。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

通常配布と B 配布の参照同士を比較する

方向	区間数	tokenizer	BLEU
英→中	1,418	zh	36.8525
中→英	2,000	13a	25.1686

SacreBLEU2.5.1 / nrefs1 / case mixed / smooth exp / eff no 。モデル出力を使った評価ではない。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. Local reference-to-reference calculation, fixed tokenization. https://github.com/mjpost/sacrebleu/tree/v2.5.1

英→中の計算例で、何を数えたか

量	出力側の全数	参照に一致する数
1-gram	82,787	54,762
2-gram	81,369	35,375
3-gram	79,951	23,833
4-gram	78,533	16,897

通常配布参照を出力側へ置く。参照側は 78,915 token 、出力側が長いため BP=1 。

[1] Post et al. SacreBLEU 2.5.1. Local reference-to-reference calculation, fixed tokenization. https://github.com/mjpost/sacrebleu/tree/v2.5.1

SGM の区間全文を、公開ファイルから読む

```
import re, tarfile, html
with tarfile.open('test.tgz') as archive:
    raw = archive.extractfile(
        'sgm/newstest2020-enzh-src.en.sgm'
    ).read().decode('utf-8')
segments = re.findall(r'<seg id="[^"]+">(.*?)</seg>', raw)
print(html.unescape(segments[910]))
```

House rebukes Trump on border wall, but he plans veto

[1] WMT20. newstest2020 / enzh / foxnews.100085 / seg 1. https://data.statmt.org/wmt20/translation-task/test.tgz

参照全 1,418 区間の BLEU を計算する

```
import re, tarfile, html
from sacrebleu.metrics import BLEU
def refs(name):
    with tarfile.open('test.tgz') as t:
        raw = t.extractfile(name).read().decode('utf-8')
    return [html.unescape(s) for s in re.findall(
        r'<seg id="[^"]+">(.*?)</seg>', raw)]
a = refs('sgm/newstest2020-enzh-ref.zh.sgm')
b = refs('sgm/newstestB2020-enzh-ref.zh.sgm')
metric = BLEU(tokenize='zh', lowercase=False)
print(metric.corpus_score(a, [b]).score)
print(metric.get_signature())
```

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. Local reference-to-reference calculation, fixed tokenization. https://github.com/mjpost/sacrebleu/tree/v2.5.1

固定版の実行と、説明用計算の条件

- get_cleva_spec には、生成の既定値として提示例上限 5 、出力 1 候補、最大 20 token 、温度 0 などがある。実際には infer_params の値で上書きされる。
- CLEVA の変換済み translation.zip を取得できていないため、この既定値を公開実行の条件とはみなさない。公開索引からも実際の翻訳 run は得られない。
- SacreBLEU2.5.1 による参照比較は、使用した参照、 tokenizer 、大小文字、全区間数を固定した独立の計算例。 CLEVA の未公開条件とは分けて再現する。

[1] Stanford CRFM. get_cleva_spec / get_cleva_machine_translation_metric_specs. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/run_specs.py

[2] Stanford CRFM. CLEVA v1 run settings, translation en2zh / zh2en. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

二方向の人手評価は、同一の方式ではない

- 2020 年の英語からの翻訳は、原文を理解できる評価者による source-based 評価。英語への翻訳は、英語の参照を使う reference-based 評価を中心とする。
- 文書の文脈を示す方法も評価方向で異なる。複数の区間をまとめて見せる構成と、区間を順に評価しながら全文書へアクセスする構成を区別する。
- したがって、英→中の平均 z と中→英の平均 z を、そのまま同じ絶対尺度の翻訳品質として比較しない。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

研究と参考文献

国際共有タスクで、翻訳を比較する

- WMT20 は Loïc Barrault 、 Magdalena Biesialska 、 Ondřej Bojar らによる国際共有タスク。第 5 回 Conference on Machine Translation として 2020 年に開催された。
- ニュース翻訳の共通テスト、参加システム、人手評価、同順位群を整備し、多言語の翻訳を比較する。英中はその一部である。
- CLEVA はこのような過去の WMT データを、言語モデルの翻訳課題へ取り込む。原データの単位と後続評価の条件を分けて読む必要がある。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

参考文献

Findings of the 2020 Conference on Machine Translation (WMT20)

Loïc Barrault et al. · 2020 · WMT, pp.1–55

ニュース翻訳の収集、参加システム、人手評価、統計的な同順位群を報告する。

https://aclanthology.org/2020.wmt-1.1/

WMT20: Shared Task — Machine Translation of News

WMT20 organizers · 2020 · Official task page

言語対、データ、段落単位の翻訳、研究利用と追加引用の条件を説明する。

https://www.statmt.org/wmt20/translation-task.html

参考文献

BLEU: a Method for Automatic Evaluation of Machine Translation

Kishore Papineni, Salim Roukos, Todd Ward, Wei-Jing Zhu · 2002 · ACL

n-gram の修正適合率と、短い出力へのペナルティによる自動評価を提案する。

https://aclanthology.org/P02-1040/

A Call for Clarity in Reporting BLEU Scores

Matt Post · 2018 · WMT Research Papers, pp.186–191

BLEU の再現性を妨げる処理条件の違いを論じ、条件を明示する評価を扱う。

https://aclanthology.org/W18-6319/

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

過去の WMT から英中翻訳を採用。公開見出し例と SacreBLEU の使用を記す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVATranslationScenario and Converter

Stanford CRFM · 2023 · HELM v0.4.0 implementation

変換済みデータとテンプレートから入力と参照を構成し、二方向の翻訳例を示す。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

get_cleva_spec and get_cleva_machine_translation_metric_specs

Stanford CRFM · 2023 · HELM v0.4.0 run specification

推論パラメータの読取、生成条件、翻訳用 metric への接続先を定義する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/run_specs.py

run_specs_cleva_v1.conf

Stanford CRFM · 2023 · HELM v0.4.0 configuration

翻訳 en2zh と zh2en に、それぞれ 0 〜 2 の三つの prompt_id を登録する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf