WMT2020 （英中）

News Translation Task

newstest2020: English to/from Chinese

ニュースの原文と参照訳で、英中の翻訳を評価する

sasakiy84

WMT20 ニュース翻訳タスクの公式サイト

EMNLP 2020
FIFTH CONFERENCE ON
MACHINE TRANSLATION (WMT20)

November 19-20, 2020
Online

Shared Task: Machine Translation of News

[HOME] [SCHEDULE] [PAPERS] [VIRTUAL CONFERENCE] [RESULTS]
TRANSLATION TASKS: [NEWS] [LIFELONG LEARNING] [ROBUSTNESS] [SIMILAR LANGUAGES] [UNSUP AND VERY LOW RES] [BIOMEDICAL] [CHAT]
OTHER TASKS: [AUTOMATIC POST-EDITING] [METRICS] [QUALITY ESTIMATION] [PARALLEL CORPUS FILTERING]

The recurring translation task of the WMT workshops focuses on news text. For this year the language pairs are:

- Chinese-English
- Czech-English (this year **both directions again**)
- French-German
- German-English
- Inuktitut-English
- Khmer-English
- Japanese-English
- Pashto-English
- Polish-English
- Russian-English
- Tamil-English

We provide parallel corpora for all languages as training data, and additional resources for download.

GOALS

[1] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

1. ニュースを、別の言語へ訳す
2. ニュース文書と参照訳の構成
3. BLEU と、 2020 年の人手評価
4. 入手と利用条件

原文の内容を、もう一つの言語へ

英語から中国語、中国語から英語へ

- WMT2020 のニュース翻訳では、入力の内容を別の言語で表す。この資料は、公開テスト newstest2020 の英語→中国語と中国語→英語を扱う。
- 入力に対応する参照訳が公開されている。参照訳は比較のために人が作った訳文で、同じ内容を表すほかの訳もあり得る。
- 英語→中国語は英語のニュース、中国語→英語は中国語のニュースを原文にしている。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例１：壁をめぐる非難と、拒否権の意向

英語から中国語へ

入力（英語）
House rebukes Trump on border wall, but he plans veto

参照訳（中国語）
众议院在边境墙问题上指责特朗普，但他计划使用一票否决权

入力の日本語訳
国境の壁をめぐり下院がトランプ氏を非難するが、同氏は拒否権を行使する意向だ。

参照訳の日本語訳
下院は国境の壁の問題でトランプ氏を非難するが、同氏は拒否権を使う予定だ。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

下院の非難と、拒否権行使の意向

- House は下院、 rebukes は非難を表す。下院の動きに対し、 but の後にはトランプ氏の反対の動きが続く。 plans は、拒否権を行使する意向を表す。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例２：女性への抑圧に抗した人物を伝える

英語から中国語へ

入力（英語）
This will help the present generation to know about the man, who had waged a war against women oppression and propagated widow remarriage, he said.

参照訳（中国語）
他说，这将有助于当代人了解这位名人，他发动了一场反对妇女压迫的战争，并鼓励寡妇再婚。

入力の日本語訳
女性への抑圧と闘い、寡婦の再婚を推進したこの人物について、現代の人々が知る助けになる、と彼は述べた。

参照訳の日本語訳
これは、女性への抑圧に反対する闘いを起こし、寡婦の再婚を奨励したこの著名人を、現代の人々が知る助けになる、と彼は述べた。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例３：固有名詞と、列挙された役職

中国語から英語へ

入力（中国語）
中国驻柬大使馆外交官仲跻法、柬华理事总会代表、柬埔寨江西商会会长魏思钰等为获奖嘉宾颁奖。

参照訳（英語）
Zhong Jifa, diplomat of the Chinese Embassy in Cambodia, and Wei Siyu, representative of the Cambodian Chinese Council and President of Jiangxi Chamber of Commerce in Cambodia, presented the awards to the winners.

入力の日本語訳
中国駐カンボジア大使館の外交官・仲跻法、カンボジア華人理事総会の代表、カンボジア江西商会会長・魏思钰らが、受賞者に賞を贈った。

参照訳の日本語訳
カンボジアの中国大使館の外交官・仲跻法と、カンボジア華人理事総会代表兼カンボジア江西商会会長・魏思钰が、受賞者に賞を贈った。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

関係節や役職を読み取り、誰が何をしたかを訳す

- 実例 2 では、長い関係節が the man を説明する。女性への抑圧と闘ったことと、寡婦の再婚を推進したことが、この人物の活動として述べられている。
- 実例 3 では、人名・機関名・役職が列挙され、受賞者へ賞を贈ったという動作につながる。原文と参照訳には、役職をまとめる表現の違いもある。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

ニュース記事を、評価用の翻訳対へ

WMT2020 全体と、英中の公開テスト

- WMT20 のニュース翻訳は、 11 言語対・ 22 方向を含む国際共有タスク。この資料は、そのうち英語・中国語の二方向を扱う。
- ニュースサイトから各言語の原文を収集し、評価用の参照訳を作成した。
- 参加者向けには、学習用の対訳・単言語コーパスや開発データも配布された。公開テストは、学習後の翻訳品質を比べるために使う。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

英→中 1,418 区間、中→英 2,000 区間

方向	区間数	文書数	原文の言語
英→中	1,418	130	英語のみ
中→英	2,000	155	中国語のみ

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

英→中では、一つの区間が複数文を含む

- 英語→中国語では、翻訳者へ段落の区切りを保った文章を渡し、翻訳時に文を結合・分割する自由度を持たせた。評価の 1 区間に、複数の文が入る場合もある。
- 公開ファイルの SGM 形式では、文書に docid 、区間に id が付く。この二つを組にして、原文と参照訳を対応付ける。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/
[2] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

同じ入力に、異なる参照ファイルがある

比較	英→中	中→英
通常配布と B 配布の入力	全 1,418 区間で一致	全 2,000 区間で一致
参照文が異なる区間	1,416 / 1,418	1,997 / 2,000
通常配布の名前	newstest2020	newstest2020
別参照を持つ名前	newstestB2020	newstestB2020

実例では、 newstest2020 の通常参照を示す。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

参照の表現が、語句の一致を変える

House rebukes Trump on border wall, but he plans veto

公開参照（中国語）	意味の日本語訳
众议院在边境墙问题上指责特朗普，但他计划使用一票否决权	下院は国境の壁の問題でトランプ氏を非難するが、同氏は拒否権を使う予定だ。
众议院就边境城一事谴责特朗普，而特朗普打算否决	下院は国境の都市の件でトランプ氏を非難し、トランプ氏は否決するつもりだ。

上： newstest2020 、下： newstestB2020 。 B 参照には「边境城」（国境の都市）という表記がある。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

学習資源の制約も、性能の条件になる

- 共有タスクには、公式に提供された学習資源の範囲で参加するconstrained 条件と、それを超える資源を使う条件がある。
- 参加システムは、対訳データや単言語データ、逆翻訳、複数モデルの組合せなどを用いた。個別のシステム構成は、各参加論文で説明されている。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

語句の一致と、人による意味の評価

BLEU は、参照訳と語句が重なる程度を測る

- BLEU は、翻訳出力と参照訳の n-gram の重なりを数える。通常は 1 〜 4-gram の修正適合率を幾何平均し、短い出力へ長さのペナルティを掛ける。
- 修正適合率は、出力中の n-gram のうち参照と一致するものの割合。一致数は参照の出現回数を上限とするため、同じ語を繰り返しても得点は伸びにくい。
- n-gram は、 n 個のトークンの連続列。各区間の一致数と長さを合計して、コーパス全体の BLEU を求める。

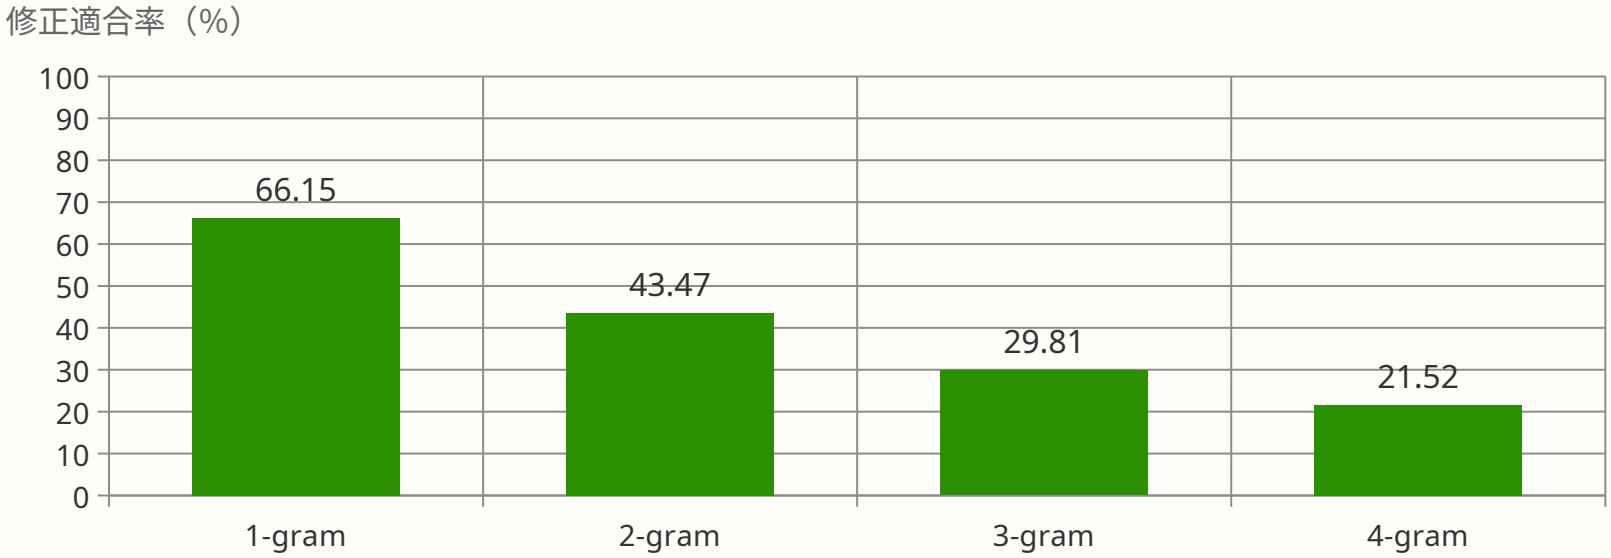
[1] Papineni, Roukos, Ward & Zhu (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. ACL. https://aclanthology.org/P02-1040/

中国語の文字の区切り方が、 BLEU に影響する

- 中国語の分割方法は、得点に影響する。 SacreBLEU の zh 分割は、漢字などを 1 字ずつに分け、非漢字部分にも区切り処理を行う。
- SacreBLEU は、参照や分割方法をそろえて BLEU を計算する評価ツール。
- 次の参照訳同士の比較では、この zh 分割で BLEU を計算した。

[1] Post (2018). A Call for Clarity in Reporting BLEU Scores. WMT, pp.186–191. https://aclanthology.org/W18-6319/
[2] Post et al. SacreBLEU 2.5.1. https://github.com/mjpost/sacrebleu/tree/v2.5.1

公開参照同士でも、 BLEU は 36.85 になる



通常配布参照を出力側、 B 配布参照を参照側に置いた計算例。英→中の全 1,418 区間。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. https://github.com/mjpost/sacrebleu/tree/v2.5.1

2020 年の人手評価は、意味の伝わり方を採点する

評価対象	平均評点	標準化平均（ z ）
HUMAN-B	80.6	0.568
HUMAN-A	82.5	0.529
OPPO	80.0	0.447
Tencent-Translation	79.0	0.420
Huawei-TSC	77.3	0.415

英→中の人手評点（ 0 〜 100 ）。 HUMAN-A/B は人手訳、 3 システムは公式の学習資源内で参加。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

人手評価は、文書の文脈を見て採点する

- 英語からの翻訳では、原文を理解できる評価者に原文と翻訳を示し、文書の文脈を見ながら意味の伝わり方を評価してもらった。
- 採点者ごとの評点を、その人の平均と標準偏差で標準化し、平均 z 得点を求める。標準化した値で評価対象を並べるため、生の平均評点とは順位が入れ替わることがある。
- 公式順位では、統計的に差があるとはいえないシステムを同順位の群にまとめている。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

公開データの入手と利用条件

研究目的で利用でき、引用と権利の条件がある

- 公式タスクページは、 WMT20 のデータを研究目的で自由に使えるとし、概要論文と各集合の追加引用条件を守るよう求める。
- それ以外の用途については、元データの権利者へ相談する条件になっている。

[1] WMT20. Shared Task: Machine Translation of News. Task, data and licensing. https://www.statmt.org/wmt20/translation-task.html

英中のニュース翻訳を、 BLEU と人手で評価する

- WMT2020 の英中公開テストは、英語→中国語が 1,418 区間、中国語→英語が 2,000 区間。ニュースの原文に、人が作った参照訳が付く。
- BLEU は参照訳との語句の一致を測り、人手評価は文脈の中で意味が伝わるかを調べる。同じ入力にも異なる参照訳があり、語句の選び方が BLEU に影響する。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

Appendix

1. 追加の公開翻訳例
2. データの読み方と評価の具体例
3. 参考文献

追加の公開翻訳例

実例 4 ： 5 日間で 500 通の手紙

英語から中国語へ

入力（英語）
A woman in Maine got 500 letters from United Healthcare within five days

参照訳（中国語）
一位缅因州女性五天内收到 500 封来自联合健康保险的信件

入力の日本語訳
メーン州の女性が、ユナイテッドヘルスケアから 5 日間で 500 通の手紙を受け取った。

参照訳の日本語訳
メーン州のある女性が、 5 日間でユナイテッドヘルスケアから 500 通の手紙を受け取った。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 5 ： SNS の「いいね」を非表示にする

英語から中国語へ

入力（英語）
Facebook hides 'likes' in new Australia trial

参照訳（中国語）
脸书在澳大利亚新测试中隐藏点“赞”数

入力の日本語訳
Facebook が、オーストラリアでの新たな試験で「いいね」を非表示にする。

参照訳の日本語訳
Facebook が、オーストラリアでの新たな試験で「いいね」の数を非表示にする。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 6 ：ハリケーンの強さと場所

英語から中国語へ

入力（英語）
Lorenzo strengthens into Category 4 hurricane east of Caribbean

参照訳（中国語）
洛伦佐在加勒比海东部增强为 4 级飓风

入力の日本語訳
ロレンゾが、カリブ海の東でカテゴリー 4 のハリケーンに発達する。

参照訳の日本語訳
ロレンゾが、カリブ海の東部でカテゴリー 4 のハリケーンに勢力を強める。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 7 ： AI を共通善のために使う

英語から中国語へ

入力（英語）
Pope warns tech execs to use AI for the common good

参照訳（中国語）
教皇方济各就技术高管使用人工智能实现公共利益发出警告

入力の日本語訳
教皇が、共通善のために AI を使うようテクノロジー企業の幹部に注意を促す。

参照訳の日本語訳
教皇フランシスコが、公共の利益のために AI を使うことについて、テクノロジー企業の幹部に注意を促す。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 8 ：礼節ある政治家を表彰する制度

英語から中国語へ

入力（英語）
A new awards scheme has been set up to recognise politicians who show courtesy in their work.

参照訳（中国語）
设立新的奖项计划是为了表彰那些礼貌得体的政治人士

入力の日本語訳
仕事で礼節を示す政治家をたたえるため、新たな表彰制度が設けられた。

参照訳の日本語訳
新たな表彰計画を設けるのは、礼儀正しく品位のある政治家をたたえるためだ。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例９：協定が許す遠心分離機を限定する

中国語から英語へ

入力（中国語）
协议规定，伊朗只能用第一代 IR-1 型离心机来提炼铀。

参照訳（英語）
The agreement stipulates that Iran can only use first-generation IR-1 centrifuges to refine uranium.

入力の日本語訳
協定では、イランがウラン精製に使えるのは第 1 世代の IR-1 型遠心分離機だけと定めている。

参照訳の日本語訳
協定は、イランがウラン精製に使えるのは第 1 世代の IR-1 型遠心分離機だけと規定する。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 10 ：クルーズ船に初めて乗る参加者

中国語から英語へ

入力（中国語）
参加此次活动的 100 余名残障人士大多是第一次登上邮轮。

参照訳（英語）
Most of the more than 100 disabled people who participated in the event had never boarded a cruise ship before.

入力の日本語訳
今回の催しに参加した 100 人余りの障害者の多くは、クルーズ船に乗るのが初めてだった。

参照訳の日本語訳
この催しに参加した 100 人余りの障害者の多くは、それまでクルーズ船に乗ったことがなかった。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 11 ： 8 月の世界販売台数を伝える

中国語から英語へ

入力（中国語）
马自达 9 月 27 日发布的数据显示，8 月全球销量为 11 万 7015 辆。

参照訳（英語）
According to data released by Mazda on September 27, global sales in August were 117015 units.

入力の日本語訳
マツダが 9 月 27 日に発表したデータによると、 8 月の世界販売は 11 万 7015 台だった。

参照訳の日本語訳
マツダが 9 月 27 日に発表したデータによると、 8 月の世界販売は 117,015 台だった。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 12 ：壁画が描く人物の生涯

中国語から英語へ

入力（中国語）
《天后圣迹图》是一幅全面反映妈祖生平的大型传统壁画。

参照訳（英語）
The Drawing of Miracles of Mazu is a large traditional mural that fully reflects Mazu's life.

入力の日本語訳
『天后聖蹟図』は、媽祖の生涯を全面的に描いた大きな伝統的壁画である。

参照訳の日本語訳
『媽祖の奇跡の図』は、媽祖の生涯を全面的に描いた大きな伝統的壁画である。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

実例 13 ：空港の供用開始の式典

中国語から英語へ

入力（中国語）
9 月 25 日，北京大兴国际机场投运仪式隆重举行。

参照訳（英語）
On September 25th, a grand opening ceremony was held for the Beijing Daxing International Airport.

入力の日本語訳
9 月 25 日、北京大興国際空港の供用開始の式典が盛大に催された。

参照訳の日本語訳
9 月 25 日、北京大興国際空港で盛大な開業式典が催された。

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

参照訳にも、具体化や語句の違いがある

実例	対応の手掛かり
5	英語の likes に対し、中国語の参照訳は点赞数と「数」であることを明示する。
6	英語の east of Caribbean はカリブ海の東。中国語の参照訳は加勒比海东部（カリブ海の東部）と表す。
7	英語は Pope （教皇）と記し、中国語の参照訳は「教皇フランシスコ」と名前を具体化する。
8	英語は表彰制度が設けられたことと、その目的を述べる。中国語の参照訳は目的を中心に表す。
9	只能と only は、使用できる機器を第 1 世代の IR-1 型に限定する。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

データの読み方と評価の具体例

通常配布と B 配布の参照同士を比較する

方向	区間数	tokenizer	BLEU
英→中	1,418	zh	36.8525
中→英	2,000	13a	25.1686

通常参照を出力側、 B 参照を比較の参照側に置いて計算。 SacreBLEU 2.5.1 、参照 1 本、大小文字を保持。

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. https://github.com/mjpost/sacrebleu/tree/v2.5.1

SGM の区間全文を、公開ファイルから読む

```
import tarfile
from lxml import etree
with tarfile.open("test.tgz") as t:
    raw = t.extractfile(
        "sgm/newstest2020-enzh-src.en.sgm").read()
data = etree.HTML(raw)
seg = data.xpath('//doc[@docid="foxnews.100085"]//seg')[0]
print("".join(seg.itertext()))
```

House rebukes Trump on border wall, but he plans veto

[1] WMT20 (2020). newstest2020 — English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz

参照全 1,418 区間の BLEU を計算する

```
import re, tarfile, html
from sacrebleu.metrics import BLEU
def refs(name):
    with tarfile.open('test.tgz') as t:
        raw = t.extractfile(name).read().decode('utf-8')
    return [html.unescape(s) for s in re.findall(
        r'<seg id="[^"]+">(.*?)</seg>', raw)]
a = refs('sgm/newstest2020-enzh-ref.zh.sgm')
b = refs('sgm/newstestB2020-enzh-ref.zh.sgm')
metric = BLEU(tokenize='zh', lowercase=False)
print(metric.corpus_score(a, [b]).score)
```

[1] WMT20. Official test.tgz: newstest2020 / newstestB2020, English–Chinese. https://data.statmt.org/wmt20/translation-task/test.tgz
[2] Post et al. SacreBLEU 2.5.1. https://github.com/mjpost/sacrebleu/tree/v2.5.1

翻訳方向ごとに、原文や参照を使って人が評価する

- 英語からの翻訳は、原文を理解できる評価者が原文と訳文を見る source-based 評価。英語への翻訳は、英語の参照訳と照らす reference-based 評価が中心となる。
- 文書の文脈を示す方法も方向によって異なる。得点は、それぞれの翻訳方向・評価方式の中で比較する。

[1] Barrault et al. (2020). Findings of the 2020 Conference on Machine Translation (WMT20). WMT, pp.1–55. https://aclanthology.org/2020.wmt-1.1/

参考文献

参考文献

Findings of the 2020 Conference on Machine Translation (WMT20)

Loïc Barrault et al. · 2020 · WMT, pp.1–55

ニュース翻訳の収集、参加システム、人手評価、統計的な同順位群を報告する。

https://aclanthology.org/2020.wmt-1.1/

WMT20: Shared Task — Machine Translation of News

WMT20 organizers · 2020 · Official task page

言語対、データ、段落単位の翻訳、研究利用と追加引用の条件を説明する。

https://www.statmt.org/wmt20/translation-task.html

参考文献

BLEU: a Method for Automatic Evaluation of Machine Translation

Kishore Papineni, Salim Roukos, Todd Ward, Wei-Jing Zhu · 2002 · ACL

n-gram の修正適合率と、短い出力へのペナルティによる自動評価を提案する。

https://aclanthology.org/P02-1040/

A Call for Clarity in Reporting BLEU Scores

Matt Post · 2018 · WMT Research Papers, pp.186–191

BLEU の再現性を妨げる処理条件の違いを論じ、条件を明示する評価を扱う。

https://aclanthology.org/W18-6319/